

## 1. 数据集数据量 (Volume)

根据项目仓库中的缓存分析文件 (analysis\_cache/indexer.pkl\_analysis.json) 和当前环境下的数据集 (dataset/TencentGR\_1k), 当前工程中包含的是一个采样数据集 (Sample Dataset), 用于开发和调试。

- 用户数量 (Users): 865 人 (基于 indexer.pkl 中的 u 字典)
- 物品数量 (Items/Creatives): 58,734 个 (基于 indexer.pkl 中的 i 字典)
- 特征字段数 (Feature Fields): 22 类 (基于 indexer.pkl 中的 f 字典)
- 文件大小:
  - indexer.pkl: 约 4.5 MB (存储了ID映射关系)
  - item\_feat\_dict.json: 存储了5.8万+物品的特征信息。
  - seq.jsonl: 存储用户行为序列 (JSON Lines格式)。

面试注意: 实际比赛的“全量数据集”通常被称为 1M数据集 或更大 (从 explore\_dataset/1m\_real\_dataset 文件夹命名可推断), 通常包含百万级用户和亿级交互。你应当说明: “在本地调试环境中使用的是约1k用户的采样集, 包含约6万个物品; 实际比赛全量数据规模通常在百万用户级别。”

## 2. 数据构成 (Composition)

数据集是以 用户行为序列 (User Behavior Sequence) 为核心构建的, 采用 seq.jsonl 文件存储。

### 2.1 数据格式

每一行数据代表一个用户的完整历史行为序列。

代码 (dataset.py) 中加载的数据结构如下:

```
1 # 每一条记录是一个元组
2 (user_id, item_id, user_feat, item_feat, action_type, timestamp)
```

### 2.2 特征体系 (Features)

数据集中包含极其丰富的多模态和上下文特征, 主要分为以下几类:

#### A. 稀疏特征 (Sparse Features)

通过 Embedding 层映射为低维向量。

- 用户侧 (User Sparse): 包含 IDs ['103', '104', '105', '109'] 等。
  - 推测含义: 用户画像特征, 如年龄段、性别、地域、设备类型等。
- 物品侧 (Item Sparse): 包含 IDs ['100', '117', '111', '118', '101', ...] 等。
  - 推测含义: 广告属性, 如广告主ID、行业分类、素材尺寸等。

#### B. 序列/数组特征 (Array Features)

不定长的特征列表, 通常通过 Pooling (Sum/Mean) 处理。

- 用户侧 (User Array): IDs ['106', '107', '108', '110']。
  - 推测含义: 用户的历史兴趣标签列表、安装应用列表等。
- 物品侧 (Item Array): 只有 ID ['113'] (代码中为空列表, 但在 indexer 中可能存在)。

#### C. 多模态特征 (Multimodal Embeddings)

这是该数据集的一大亮点, 利用预训练模型提取的 Embedding。

- 特征 IDs: ['81', '82', '83', '84', '85', '86']

- 维度 (Dimensions):
  - 81: 32维 (可能是一些基础统计特征或小型Embedding)
  - 82: 1024维 (可能是文本 BERT Embedding)
  - 83 ~ 86: 3584维 / 4096维 (典型的大模型图像/视频特征, 如 ResNet, CLIP, VideoMAE 等提取的向量)
- 存储: 存储在 creative\_emb 目录下, 通过 mmap 或内存加载。

#### D. 时间特征 (Time Features)

在 dataset.py 中动态构造, 用于捕捉时序规律:

- 基础时间: 小时 (0-23), 星期 (0-6), 月份。
- 相对时间:
  - log\_duration: 行为间隔的对数。
  - time\_decay: 时间衰减因子。
  - time\_diff: 与序列首元素的时间差。

### 3. 数据分布 (Distribution)

#### 3.1 正负样本分布

推荐系统 (特别是序列推荐) 的训练方式决定了样本的定义:

- 原始数据: seq.jsonl 中包含的全都是正样本 (即用户实际点击/交互过的序列)。没有显式的负样本记录。
- 训练时 (On-the-fly):
  - 正样本 (Pos): 序列中的“下一个物品” (Next Item)。例如, 已知历史 [A, B, C], 预测 D。D 就是正样本。
  - 负样本 (Neg): 动态随机采样。代码 \_random\_neg 函数从所有物品集合中随机抽取一个不在当前用户历史序列中的物品作为负样本。
- 比例 (Ratio): 1 : 1。
  - 在 Dataset.getitem 中, 对于序列中的每一个时间步, 模型都会生成 1 个正样本 (真实点击) 和 1 个负样本 (随机采样)。
  - 面试官问法: “你们怎么处理负样本的?” -> 回答: “采用动态负采样, 训练时针对每个正样本实时采样一个未交互过的物品作为负样本, 比例为1:1, 使用 BPR Loss 或 CrossEntropy Loss 进行优化。”

#### 3.2 序列长度

- Max Length: 代码中通过 args.maxlen 控制 (常见配置为 100 或 200) 。
- Padding: 采用 Left-Padding (从后往前填充), 不足部分补 0。这符合序列预测任务 (预测序列的最末端) 的习惯。

#### 3.3 冷启动处理 (Test Set)

- 测试集 (MyTestDataset): 会遇到训练集中未见过的 Item 或 User。
- 处理策略: 代码 \_process\_cold\_start\_feat 显示, 对于新出现的特征值 (字符串类型), 会默认填充为 0 (Unknown) 或使用特征的默认 Embedding, 保证模型不会报错, 但这也意味着模型对纯冷启动物品主要依赖泛化特征 (如多模态特征) 而非 ID特征。

"该数据集是一个典型的多模态序列推荐数据集。虽然我本地调试使用的是约1k用户、6万物品的采样集，但其结构非常完整。

它不仅包含常规的用户ID和物品ID，还引入了20多种稀疏和数组特征。最关键的是，它集成了维度高达4096维的多模态Embedding（涵盖文本、图像或视频特征），这要求模型具有强大的多模态融合能力。

在训练分布上，由于是隐式反馈数据，我们仅拥有正向点击序列。因此，训练阶段采用了动态负采样策略，在每个Time Step以 1:1 的比例构造正负样本对，迫使模型学习用户兴趣的边界。"